

Projet 1 : Étude sur les liens entre start-ups et structures d'enseignement supérieur et de recherche

1. Thème du projet et jeu de données utilisé

Dans ce projet, vous allez analyser la base de données des start-ups liées à l'Enseignement Supérieur et à la Recherche (ESR) français. L'objectif est de comprendre et visualiser les partenariats entre les structures publiques d'enseignement et de recherche et les entreprises de type start-up avec qui elles travaillent.

Le jeu de données à utiliser se trouve sur le site [data.gouv.fr](https://www.data.gouv.fr), à l'adresse suivante :

<https://www.data.gouv.fr/datasets/les-start-ups-liees-a-lenseignement-superieur-et-a-la-recherche-academique-francaise>.

Votre mission est de comprendre et de préparer le jeu de données, avant de programmer des fonctions pour l'explorer et en tirer des connaissances nouvelles. Ces connaissances seront extraites du jeu de données par une approche statistique.

2. Travail demandé

Toutes les questions de cette partie sont obligatoires et communes à tous les binômes. Y répondre parfaitement n'est pas suffisant pour obtenir la note maximale.

Si une étape de la préparation ou de l'analyse vous a posé problème et que vous avez dû prendre une décision (ne pas traiter, envisager un traitement particulier des données), mentionnez-le dans le rapport avec les choix que vous avez faits.

2.1 Importation et préparation des données

1. Importez directement depuis l'URL de téléchargement la base de données des Startups liées aux structures d'enseignement supérieur et de recherche françaises.
2. Modifiez les types de données dans les colonnes (dates, attributs catégoriels, attributs booléens...) pour être le plus précis possible.
3. Affichez le résumé technique du tableau (vérifiez que vos colonnes ont un type qui vous convient).
4. Comme vous avez pu le constater, les entrées de certaines colonnes sont multi-valuées, c'est-à-dire qu'elles peuvent contenir plusieurs valeurs séparées par des virgules. Vous allez devoir gérer ce type de données. Pour cela, créez une fonction **ensemble_valeurs** qui prend en argument un DataFrame et un nom de colonne et qui renvoie sous forme d'ensemble toutes les valeurs mentionnées entre virgules dans la colonne donnée en argument.

5. Récupérez dans des variables (ensembles) au nom bien choisi les ensembles de valeurs de toutes les colonnes pouvant contenir des valeurs multiples.
6. Faites en sorte d'enregistrer la base de données nettoyée dans un fichier csv.

2.2 Traitement des données

À partir de maintenant, vous ne travaillerez plus qu'avec le tableau de données nettoyé par vos soins dans la partie précédente. L'analyse va se concentrer sur quatre aspects de la base de données : l'organisation des partenariats entre structures d'enseignement supérieur et de recherche et start-ups, l'implantation géographique des start-ups, les start-ups ayant cessé leur activité et les différents actifs produits par les start-ups en lien avec l'ESR.

Organisation des partenariats

1. Définissez une fonction **startups_liees** qui prend en argument un DataFrame et un nom de structure ESR et qui renvoie le DataFrame des startups liées à cette structure.
2. Définissez une fonction **st_partenaires** qui prend en argument un DataFrame et un nom de structure et qui renvoie l'ensemble des structures ESR partenaires d'une startup liée avec la structure donnée en argument. La structure donnée en argument ne doit pas faire partie de l'ensemble retourné par la fonction.

Implantation géographique

3. Définissez une fonction **nb_par_lieu** qui prend en argument un DataFrame et un nom de colonne ('Commune', 'Département' ou 'Région') et qui renvoie la Series pandas dont l'index correspond aux valeurs (lieux) possibles de la colonne en argument, et chaque valeur est le nombre d'entreprises ('SIREN') pour le lieu considéré.
4. Définissez une fonction **impl_partenaires** qui prend en argument un DataFrame, un nom de structure ESR et un nom de colonne ('Commune', 'Département' ou 'Région'), et qui renvoie la Series pandas contenant les nombre de start-ups partenaires de la structure regroupées par lieu, triée par ordre décroissant.

Startups ayant cessé leur activité

5. Définissez une fonction **startups_fermées** qui prend en argument un DataFrame et renvoie la base des startups du DataFrame ayant cessé leur activité, augmentée d'une nouvelle colonne de type timedelta64 dont chaque entrée est la durée de vie de la start-up considérée.
6. Définissez une fonction **partenaires_fermées** qui prend en argument un DataFrame et un nom de structure ESR et qui renvoie la base des start-ups partenaires de la structure qui ont cessé leur activité, avec une colonne contenant leur durée de vie.
7. Extrayez les nombres de startups fermées par région.

8. Calculez et stockez dans des variables la durée de vie moyenne des startups fermées, puis la durée de vie moyenne par région.

Actifs produits par les entreprises

9. Définissez une fonction **avec_actif** qui prend en argument un dataframe et un nom d'actif (présent dans l'ensemble actifs) et qui construit la base des entreprises ayant au moins un actif du type donné en entrée (indexée par les n° SIREN)
10. Construisez une fonction **nb_par_categorie** qui, à partir d'un DataFrame, d'une colonne et un ensemble, crée un DataFrame indexé par l'ensemble contenant les nombres d'occurrence de chaque élément de l'ensemble dans la colonne donnée.
11. Définissez une fonction **nb_startup_actif** qui, étant donnée un DataFrame et un type d'actif (brevet, logiciel...), renvoie le nombre d'entreprises possédant un actif du type donné en argument.
12. Pour chaque actif, calculez la proportion de startups avec cet actif parmi les entreprises ayant au moins un actif à leur compte et stockez les résultats dans un dictionnaire (les clés seront les types d'actifs et les valeurs les pourcentages correspondants).
13. Définissez une fonction **tracer_rep_actifs** qui prend en argument un DataFrame et qui produit et affiche un diagramme représentant pour chaque actif la proportion d'entreprises qui en possèdent parmi toutes les entreprises ayant au moins un actif.

2.3 Programme d'affichage des résultats de l'analyse

En utilisant toutes les fonctions que vous avez définies précédemment, écrivez un programme qui :

- affiche son titre (par exemple « étude sur les start-ups liées à l'ESR français ») ;
- affiche les noms de toutes les structures d'ESR présentes dans la base ;
- demande à l'utilisatrice de saisir le nom d'une structure d'ESR ;
- édite un rapport en représentant sous forme de texte, de tableau ou de graphique (à vous de choisir) le nombre de start-ups liées à la structure saisie, le nombre de start-ups partenaires par département, la durée de vie moyenne des start-ups partenaires fermées (au total et par département), ainsi que la répartition des actifs parmi les start-ups partenaires de la structure.


3. Exemples d'extensions possibles

La partie commune du projet vous a permis d'écrire un programme que l'utilisateur·ice intéressé·e pourra utiliser afin d'analyser et de visualiser les données sur les start-ups liées à l'enseignement supérieur et à la recherche française. Le programme en lui-même ne contient pas beaucoup de fonctionnalités : vous avez pour mission d'améliorer ce programme en utilisant vos connaissances en programmation Python, ou en mettant à contribution votre curiosité !

On propose ici un certain nombre de fonctionnalités complémentaires ou d'améliorations possibles. **Vous devez faire au moins une extension**, soit choisie parmi celles proposées ci-dessous, soit imaginée par vos soins. Cette extension peut utiliser n'importe quel module Python même s'il n'a pas été vu en cours, mais chaque membre du binôme doit être capable d'expliquer à quoi sert ce module et comment il s'utilise. **Pour chaque extension choisie, votre programme principal devra être modifié en conséquence.**

Voici une liste d'extensions qui vous sont proposées :

- choisir d'autres analyses à effectuer et à représenter sur les données des start-ups (et justifier vos choix d'analyses dans le rapport) ;
- créer un menu qui s'affiche dans le terminal afin de pouvoir choisir (par saisie clavier) l'analyse à effectuer et les résultats ou graphiques à afficher : l'utilisateur pourra sélectionner l'action à effectuer par saisie clavier. L'image suivante montre un exemple qui pourra être adapté ;



```
Analyse des données des start-ups liées à l'ESR français
Choisissez l'action à effectuer :
1- Startups partenaires d'une structure
2- Implantation géographique des partenariats
3- Étude sur les startups fermées
4- Actifs produits par les entreprises
autre- Quitter
```

- à partir de la base des start-ups, créer une base complémentaire indexée par les structures ESR et contenant pour chaque structure la liste des start-ups liées, puis mener une analyse comparable à celle que vous avez menée sur la base des start-ups ;
- croiser les données sur les start-ups avec une autre base de données et effectuer des calculs pour en tirer d'autres informations pertinentes (par exemple les données des villes où sont situées les structures ESR, pour comprendre si les start-ups sont plus liées aux structures de telle ou telle région) ;
- utiliser le module Geopandas pour représenter les informations sur une carte géographique (implantation des start-ups en France, implantation des start-ups liées à une structure donnée...)