

Rapport de projet

Analyse et prédiction de la valeur marchande des gardiens des cinq grands championnats européens (2018-2023)

Quentin Ruel – Olivier Baudouin

Introduction :

Ce rapport présente les choix techniques et méthodologiques que nous avons faits dans le cadre du projet 3. L'objectif était de construire un modèle de machine learning permettant de prédire la valeur marchande des gardiens des cinq grands championnats européens.

Le script Python est organisé en quatre parties : la préparation des données, l'analyse et la visualisation, la prédiction par machine learning, et enfin la mise en place d'un programme interactif. Nous avons aussi créé une extension qui permet de consulter la fiche individuelle d'un gardien choisi, sa valeur marchande réelle et prédite ainsi que l'évolution de cette dernière au fil des saisons.

1. Importation et préparation des données :

Nous avons utilisé deux sources de données libres. La première est un fichier CSV hébergé sur GitHub contenant les statistiques détaillées des gardiens issues de FBref. La seconde provient du projet du projet transfermarkt-datasets de David Caribou (dcaribou), également sur GitHub, qui publie sous forme de CSV compressés les valeurs marchandes historiques et les informations personnelles des joueurs issues de Transfermarkt.

Le chargement du fichier FBref se fait directement avec pandas via l'URL raw de GitHub. Pour les fichiers Transfermarkt compressés au format .csv.gz, c'était plus compliqué car pandas ne parvenait pas à lire directement l'URL. Nous avons donc créé une fonction `charger_csv_gz()` qui télécharge le fichier avec le module `requests`, le décompresse en mémoire avec `gzip`, puis le charge dans un `DataFrame`. Nous avons récupéré deux tables distinctes : une contenant les valeurs marchandes des joueurs au fil des saisons (`df_valuations`), et une autre contenant les informations des joueurs (`df_players`).

La difficulté principale était de relier les deux sources. La table `df_valuations` contient un historique de valorisations (plusieurs par saison et par joueur), identifiées par un `player_id` sans nom ni poste. Il a donc fallu la joindre avec la table `df_players` pour récupérer les noms et filtrer les gardiens des 5 grands championnats. Ensuite, pour chaque gardien et chaque saison, nous avons gardé la dernière valorisation de la saison grâce à la fonction `attribuer_saison()`.

Avant de joindre les données avec la table FBref, nous avons sélectionné quelques variables présentes uniquement dans `df_players` qui nous semblaient pertinentes pour estimer la valeur marchande des gardiens. Nous avons ensuite pu effectuer la jointure avec les données FBref sur le nom du joueur et la saison.

Plusieurs variables ont été créées ou transformées pour enrichir le modèle :

- L'âge encodé au format « années-jours » (par exemple 31-168), a été converti en décimal avec la fonction `convertir_age()`.

- La date d'expiration du contrat a été transformée en nombre de mois de contrat restants à la fin de la saison. De cette manière, on peut utiliser cette variable dans nos modèles.
- On a gardé les 10 nationalités les plus représentées telles quelles, et nous avons regroupé les restantes dans la catégorie « other » pour éviter le surapprentissage.
- Nous avons créé le pourcentage de victoires (win_pct) et les arrêts par 90 minutes (saves_per90) qui nous paraissaient une très bonne plus-value pour notre modélisation.
- Enfin, la variable market_value_prev qui représente la valeur marchande de la saison précédente a été construite avec un décalage temporel (shift). Nous l'avons créé après avoir vu que notre premier modèle ne performait pas comme nous le souhaitions.

Nous avons initialement prévu d'utiliser la saison 2023-2024 comme jeu de test (une base à part regroupant les stats des gardiens pendant cette saison est disponible sur le GitHub de FBref), mais nous nous sommes rendu compte que les données étaient incomplètes et s'arrêtaient en mars 2024 : la saison était donc incomplète, ce qui biaisait les statistiques par rapport aux saisons précédentes. Nous avons donc opté pour un découpage plus fiable entre nos données Train et Test :

- Échantillon Train : Saisons 2018-2019 à 2021-2022
- Échantillon Test : Saison 2022-2023

2. Analyse et visualisation :

Nous avons réalisé 3 analyses statistiques sur l'ensemble des données (les 5 saisons). Chacune comporte une fonction de calcul qui retourne un DataFrame, et une seconde qui renvoie un affichage graphique.

Analyse 1 – Évolution de la valeur marchande par ligue :

Cette analyse montre comment la valorisation moyenne des gardiens évolue selon les championnats. On a choisi d'afficher un tableau dans le terminal, ainsi qu'un graphique linéaire pour visualiser intuitivement et clairement les évolutions.

Analyse 2 – Matrice de corrélation :

Nous voulions mettre en lumière les statistiques qui sont corrélées à la valeur marchande des gardiens, et celles qui ne le sont pas. Pour cela, nous avons créé la heatmap des corrélations de Pearson que nous avons rapidement analysé dans le terminal, et affiché dans la fenêtre Graphes.

Analyse 3 – Top 20% vs Bottom 20% :

Cette analyse nous permet d'assurer que les très bon gardiens (top 20%) ont des statistiques significativement meilleurs que les mauvais gardiens (bottom 20%). De plus, cette comparaison met en lumière les différences de profil entre ces deux catégories de gardiens. Nous avons affiché les résultats dans le terminal ainsi que sous forme de tableau dans la fenêtre Graphes, en plus d'une comparaison des statistiques en % en graphique en barres.

3. Prédiction :

Notre objectif est de modéliser la valeur marchande des gardiens pour la saison 2022-2023. Comme c'est une variable numérique, nous avons utilisé une méthode de prédiction et non de classification.

Avec une cinquantaine de variables, il nous paraissait évident de procéder à une sélection avant de se lancer dans la modélisation. Pour cela, nous avons réalisé une sélection forward : à chaque étape, on ajoute la variable qui maximise le R^2 moyen en validation croisée, et on s'arrête quand l'amélioration n'est plus significative (inférieure à 0.005).

Le modèle que nous avons choisi est un Gradient Boosting Regressor qui nous semblait adapté à notre problématique car il capte les relations non linéaires et les interactions entre variables, ce qu'une régression linéaire classique ne permet pas. Par exemple, l'effet de l'âge sur la valeur marchande n'est pas linéaire. La variable cible a été passée en log pour gérer l'asymétrie de la distribution des valeurs marchandes (quelques centaines de milliers d'euros à plus de 50 millions). Cela permet au modèle de traiter équitablement toutes les tranches de valeur.

Au cours de nos essais de modélisations, nous nous sommes vite rendu compte que malgré tout ce qu'on tentait, les résultats de la prédiction sur l'échantillon Test n'étaient pas concluants. C'est pour cette raison qu'on a créé la variable `market_value_prev` que nous avons ajouté par la suite dans le modèle.

Modèle sans valeur marchande précédente :

Dans un premier temps, nous avons essayé de prédire la valeur marchande uniquement à partir des performances et caractéristiques des gardiens. La sélection forward a retenu 7 variables : `gk_games_starts`, `international_caps`, `age`, `win_pct`, `gk_pct_goal_kicks_launched`, `foot_both` et `gk_passes_length_avg`. Le R^2 en validation croisée était satisfaisant (environ 0.76), mais chutait à 0.37 sur l'échantillon Test. Le modèle avait du mal à généraliser, ce qui signifie que les stats de performance et les caractéristiques seules ne suffisent pas à expliquer la valorisation d'un gardien.

Modèle avec valeur marchande :

En ajoutant `market_value_prev` comme variable candidate, les résultats s'améliorent grandement. La sélection forward ne retient cette fois que 4 variables : `market_value_prev`, `gk_clean_sheets_pct`, `age` et `gk_games_starts`. Le R^2 en validation croisée est d'environ 0.89, et restait très satisfaisant sur les données Test à 0.81. On remarque que la valeur marchande précédente concentre plus de 86% de l'importance du modèle, ce qui confirme que la valeur marchande est très inertielle. Les 3 autres variables apportent des ajustements pertinents : la performance pure (pourcentage de clean sheets), l'âge (dépréciation naturelle) et le statut de titulaire (le nombre de matchs débutés).

4. Programme et extension :

Le programme s'articule autour d'un menu dans le terminal qui propose 8 actions : les trois analyses statistiques, les résultats des deux modèles de prédiction, la comparaison visuelle entre les deux, la fiche d'un gardien en particulier (extension), et la sortie du programme. Les données sont chargées et les modèles entraînés au lancement du script, ce qui permet ensuite de naviguer dans le menu sans temps d'attente.

Extension – fiche gardien :

L'extension permet à l'utilisateur de saisir le nom d'un gardien parmi ceux disposant d'une prédiction pour la saison 2022-2023. Le programme affiche alors ses informations personnelles (nom, date de naissance, nationalité, club(s), ligue(s), pied fort et le nombre de sélections internationales) dans le terminal. De plus, il indique aussi sa valeur marchande réelle et prédite à date ainsi que l'écart entre les deux, et un graphique montrant l'évolution de sa valeur marchande au fil des saisons avec un point pour la prédiction de la saison 2022-2023.

Conclusion :

Nous avons adoré réaliser ce projet. Le fait que le sujet soit libre nous a permis de choisir un thème qui nous passionnait, à savoir lier football avec programmation, statistiques et modélisation.

Même si les résultats de la modélisation ne sont pas terribles terribles (prédire la valeur marchande en grande partie grâce à la valeur marchande précédente, ce n'est pas ce que nous avions en tête à la base mais c'est ce qui performait le mieux), nous avons pris beaucoup de plaisir à mettre en place tout cela. Dommage qu'il y ait des restrictions concernant la récupération des données, car nous n'avons donc pas pu utiliser l'API SCOUTASTIC de Transfermarkt qui nous aurait sans doute permis de réaliser de meilleures analyses.

Ayant personnellement l'ambition de travailler en tant que data analyst dans le domaine du sport, je pense que cette expérience m'aura été très bénéfique pour la suite et me confirme mes envies de carrière.