

Projet 3 : Préparation, analyse et prédiction

1. Thème du projet

Dans ce projet, vous devrez choisir le jeu de données sur lequel vous allez travailler. Il vous est demandé de sélectionner **parmi les jeux de données libres** (acquis sur data.gouv.fr ou via une API sans authentification mais PAS par web scraping) **un jeu de données de votre choix**. Vous devrez référencer le jeu de données choisi dans votre rapport. Vous êtes encouragé-es à choisir un jeu de données dont le sujet vous plaît. **Les jeux de données étudiés en cours et dans les projets précédents sont interdits.**

Il vous faudra développer sur votre jeu de données les trois aspects du traitement de données vus en cours. Ces aspects sont les suivants.

- la préparation des données : sélection des attributs pertinents pour l'analyse, conversion des types, gestion des valeurs manquantes
- l'analyse et la visualisation de ces données : création de fonctions adaptées au sujet, utilisation des librairies de représentation graphique
- la prédiction et la classification : utilisation du module scikit-learn pour classifier (de manière supervisée ou non) les données étudiées

Comme pour les autres projets, l'usage de l'IA générative est fortement déconseillé. Toute utilisation d'un assistant de programmation IA doit être pertinente et motivée dans le rapport. Le vibe coding est interdit.

2. Travail demandé

Ce projet est volontairement moins guidé que les précédents. Votre rendu peut être assez court, ce n'est pas sa longueur mais sa qualité et le fait que vous vous soyez posé les bonnes questions quant à la structure de vos données qui sera pris en compte dans l'évaluation.

2.1 Préparation des données

Définissez **une fonction d'importation des données** qui générera un DataFrame pandas à partir de la source de votre choix (téléchargement d'un csv depuis une url, requête à une API). Les colonnes de votre DataFrame devront toutes être converties au type le plus pertinent. Cette fonction d'importation des données peut bien évidemment faire appel à des fonctions auxiliaires selon la nature de vos données.

2.2 Analyse et visualisation

Effectuez **trois analyses statistiques** sur votre jeu de données. Chaque analyse devra comporter deux composantes : une fonction dédiée au calcul proprement dit qui devra prendre en entrée votre DataFrame et renverra un autre DataFrame ou une valeur (numérique, textuelle, ...), et une fonction d'affichage (production d'un graphique ou affichage textuel dans le terminal).

2.3 Prédiction et classification

Identifiez dans votre jeu de données **une tâche de classification ou de prédiction** qui vous paraît pertinente (régression linéaire pour des valeurs numériques, classification supervisée ou non selon l'information que vous espérez retirer) et effectuez-la sur votre jeu de données. La pertinence de votre choix sera moins évaluée que sa mise en œuvre.

2.4 Programme

Écrivez un programme permettant à l'utilisatrice qui le lancera d'effectuer depuis le terminal les analyses que vous proposez. L'interface graphique n'est pas nécessaire.

3. Extension

Il vous est demandé de proposer **exactement une** extension de votre projet. **L'extension que vous proposez dans le projet 3 ne doit pas avoir été déjà traitée par votre binôme dans les projets précédents.** Certaines idées sont proposées ici mais vous êtes libres de choisir une autre approche si vous le désirez.

- **Focus sur l'analyse de données** : selon les données que vous avez choisi de traiter, il sera peut-être intéressant de croiser les informations contenues dans votre jeu de données avec d'autres informations trouvables librement sur le net. Vous pourrez donc télécharger un autre jeu de données et effectuer une à deux analyses supplémentaires.
- **Focus sur la prédiction et la classification** : vous pourrez mettre en œuvre plusieurs tâches de classification et de prédiction parmi celles proposées dans le module scikit-learn, afin d'en retirer des informations nouvelles.
- **Focus sur la préparation des données** : si votre jeu de données est formaté de manière particulièrement lacunaire ou incohérente (pensez au Répertoire National des Associations !), l'effort mis dans la préparation des données peut être considéré comme une extension à part entière. Dans ce cas, vous devrez le mentionner dans le rapport.
- **Interface graphique** : si vous avez envie de vous former sur la mise en place d'interfaces graphiques en Python (module tkinter), vous pouvez proposer une interface graphique pour votre programme.

Dans tous les cas, l'utilisation d'un module python autre que ceux vus en cours doit être mentionnée et expliquée dans le rapport. Pas besoin d'une documentation exhaustive mais détaillez les principales fonctions que vous utilisez.