

Modélisation de la Probabilité de Défaut de Paiement

Analyse par Scoring de Crédit : Approches Logit et Probit

Quentin Ruel

Master 1 ESA - Université d'Orléans

Avril 2026



Plan de la présentation

- ➊ Introduction
- ➋ Analyse descriptive
- ➌ Modélisation
- ➍ Performances
- ➎ Conclusion


Introduction - Contexte et problématique

- Le **risque de crédit** est un enjeu majeur pour les établissements financiers
- Le **scoring de crédit** permet d'évaluer la probabilité de défaut d'un emprunteur
- **Problématique** : dans quelle mesure les caractéristiques socio-économiques et l'historique de remboursement permettent-ils de prédire le défaut de paiement ?

Données : 30 000 clients, 23 variables explicatives, période avril-septembre 2023


Méthode : modèles Logit et Probit estimés par maximum de vraisemblance

Analyse descriptive - Répartition de la variable cible




22,1 % de défauts vs **77,9 %** de non-défauts : déséquilibre classique en scoring.

Analyse descriptive - Facteur clé : le retard de paiement



Le taux de défaut passe de **~15 %** (sans retard) à **~80 %** (retard de 3 mois).

Analyse descriptive - Taux de défaut selon le profil



Hommes : **~24 %** de défaut vs Femmes : **~21 %**. Niveau d'éducation et situation familiale aussi significatifs.

Modélisation - Sélection de variables

- Base initiale : **23 variables** avec forte multicolinéarité (encours et remboursements sur 6 mois corrélés à $> 0,9$)
- **Procédure stepwise** (critère AIC) : réduction à **18 variables**

Variables retenues : profil sociodémographique (5), retards de paiement (4), encours (3), montants remboursés (6)


Critère	Modèle complet	Modèle sélectionné
AIC	27 925	27 918

Variables les plus significatives (Logit) :


Variable	Coef.	Interprétation
Retard sept.	+0,578	$\times 1,78$ l'odds de défaut
Situation familiale	-0,154	Réduit le risque
Sexe (femme)	-0,108	Risque inférieur
Éducation	-0,101	Plus diplômé = moins de risque

Cohérence Logit-Probit : coefficients Logit $\approx 1,6 \times$ Probit.

Modélisation - Effets marginaux



Retard sept. : **+8,6 points** de probabilité de défaut par niveau de retard.



Performances - Récapitulatif

Critère	Logit	Probit
AUC	0.7241	0.7232
Accuracy	81.1%	80.6%
Seuil optimal	0.2564	0.2629
AIC	27918	28120
BIC	28076	28278

- $AUC \approx 0,72$: discrimination acceptable
- Logit légèrement supérieur (AIC, BIC)
- Résultats confirmés sous R, Python et SAS

Principaux résultats :

- L'historique de retard de paiement est le prédicteur dominant du défaut
- Les variables sociodémographiques (sexe, éducation, situation familiale) jouent un rôle significatif mais secondaire
- Logit et Probit fournissent des résultats très proches ; le Logit est privilégié (AIC inférieur, interprétabilité)

Limites et perspectives :

- AUC de 0,72 : performance modérée
- Pistes d'amélioration : variables supplémentaires (revenus), méthodes de machine learning